Прогнозирование последовательностей 32 признаков с упором на фича-инжиниринг: PCA и режимно-взвешенная VAR(p) с предсказанием остатка с помощью GRU

Чистяков Никита Алексеевич Б05-312

Аннотация

В работе рассматривается задача прогнозирования следующего шага многомерной последовательности признаков. Данные имеют структуру наборов последовательностей (идентификатор `seq_ix`) с временным индексом `step_in_seq` и индикатором `need_prediction`, задающим точки, где качество прогноза особенно важно. Для уменьшения размерности используется PCA (8 факторов), а динамика факторов моделируется в виде режимно-взвешенной VAR(p) с ridge-регуляризацией. Валидация проводится разбиением по `seq_ix`. Итоговая модель достигает среднего $R^2 \approx 0.273$ по 32 измерениям на валидации в точках `need_prediction=1` (а с применением методов ML R^2 0.3795 на приватной выборке на соревновании WunderFund RNN Challenge никнейм ivn1k), в то время как наивная персистентность $x_{t+1} \approx x_t$ даёт отрицательное качество ($R^2 \approx -0.4$).

1 Введение

Многие прикладные задачи сводятся к прогнозированию следующего шага многомерной последовательности (в частности финансовые показатели). В данной работе рассматривается набор последовательностей длины 1000 (внутри каждого `seq_ix`) с 32 числовыми признаками (колонки `0`–`31`). Требуется предсказывать вектор признаков на шаге $t+1$ (по информации до шага t), при этом качество R^2, считаеся только там где `need_prediction=1` (в тестовом примере это с 100 по 10000-ю шаги в рядах).

2 Краткий обзор подходов

Для описания линейной динамики многомерных рядов была использована VAR-модель по факторному пространству (в факторное пространство перевели данные с помощью

PCA). Также была придумана идея моделировать переходы состояний портфеля с помощью процесса блуждания, для этого были использованы уже готовые режимные модели (например HMM) и с помощью них была промоделирована одна из основных фичей в модели - волатильность. Также были использованы ARCH/GARCH-подходы и в последствии была реализована gru по остаткам в качестве ML метода.

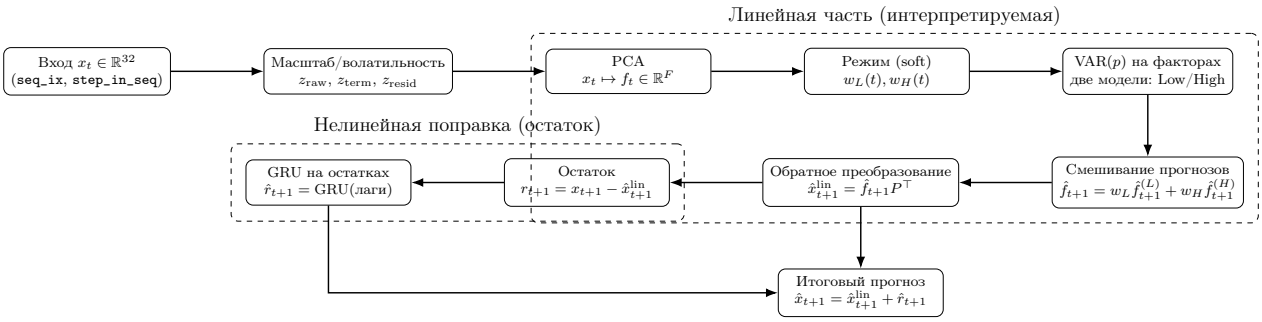

Рис. 1: Схема полной модели.

3 EDA

В датасете 517,000 наблюдений и 35 столбцов: идентификаторы `seq_ix`, `step_in_seq`, `need_prediction` и 32 числовых признака (`0`–`31`). Пропусков нет. Судя по коэффициентам асимметрии (это просто трейтий момент, skew) распределения всех фичей близки к симетричным (получается логарифмировать фичи не нужно для симетризации) и линейные модели будут в целом применимы. Эксцесс (четвёртый момент) у основной массы фичей тоже близ к нулю, но только у первых 5 фичей в той табличке будут тяжелее хвосты.

Внутри одной последовательности траектории признаков заметно меняют масштаб (рис. 2). То есть если рассматривать в контексте не проекции на одну размерность, а на весь вектор в совокупности, то будет видна сильная масштабируемость вектора.

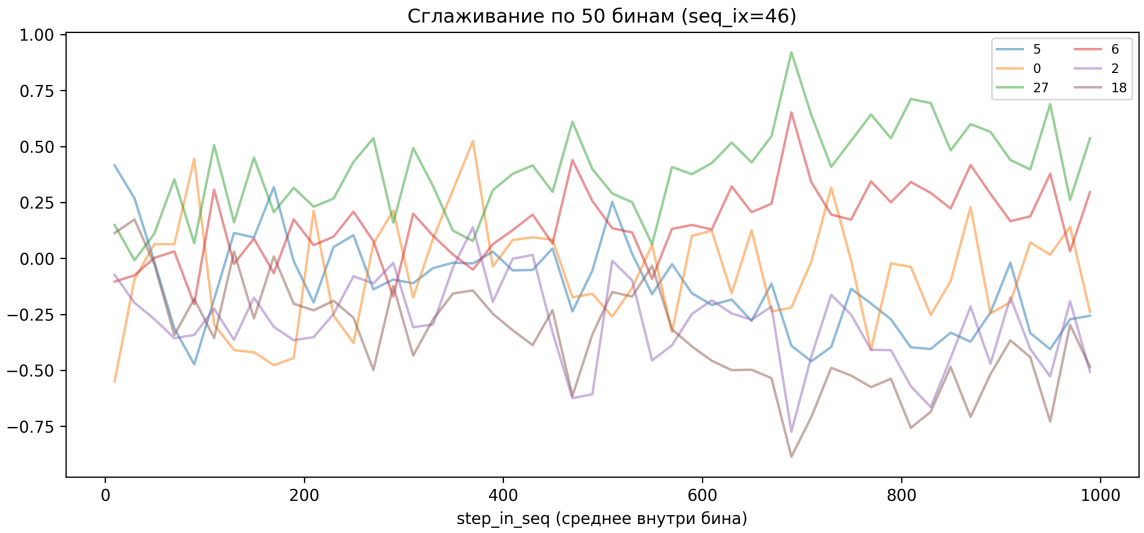

Рис. 2: Пример траекторий нескольких признаков внутри одной последовательности.

3.1 Гетероскедастичность приращений

На примере одного случайного признака (в данном случае признака 0) видна неоднородность данных: рассмотрим приращение у этого признака $\Delta x_t = x_{t+1} - x_t$ и зависимость $\mathrm{std}(|\Delta x|)$ от уровня $|x|$ в бинах по $|x|$. Наблюдается рост дисперсии приращений с увеличением $|x|$ (рис. 3), что подтверждается тестом Бройша–Пагана: ≈ 34751.8 при $p \approx 0$. Поэтому попробуем найти преобразование приращений, которое уберёт гетероскедастичную часть ряда.

3.2 CEV-преобразование для стабилизации дисперсии приращений

Во многих моделях для цен активов и форвардов уровень-зависимая волатильность задаётся CEV-динамикой (constant elasticity of variance), обобщающей геометрическое броуновское движение:

$$dS_t = \mu S_t\, dt + \sigma S_t^{\beta}\, dW_t, \tag{1}$$

где W_t — броуновское движение, μ — дрейф, $\sigma > 0$ — масштаб (волатильность), β — параметр эластичности дисперсии.

Интерпретация β:

$\beta = 1$ соответствует модели Блэка–Шоулза,

$\beta = 0$ — модели с примерно постоянной волатильностью в абсолютных единицах,

$0 < \beta < 1$ — промежуточный случай.

Из SDE следует, что условная дисперсия малых приращений зависит от уровня степенным образом:

$$\mathrm{Var}(dS_t \mid S_t) \approx \sigma^2 S_t^{2\beta}\, dt. \tag{2}$$

В дискретном приближении на малом шаге Δt получаем

$$|\Delta S_t| \approx \sigma |S_t|^{\beta} \sqrt{\Delta t}\, |\varepsilon_t|, \qquad \varepsilon_t \sim \mathcal{N}(0,1), \tag{3}$$

и, беря логарифм,

$$\log |\Delta S_t| \approx \text{const} + \beta \log |S_t| + \text{шум}. \tag{4}$$

Поэтому регрессия $\log |\Delta x|$ на $\log |x|$ даёт оценку $\hat{\beta}$, а нормировка

$$\Delta x_t^{(\text{cev})} = \frac{\Delta x_t}{|x_t|^{\hat{\beta}} + \varepsilon} \tag{5}$$

(с малым $\varepsilon > 0$, чтобы предотвратить деление на нуль)

По оценке OLS получено $\hat{\beta} \approx 0.183$. После преобразования статистика Бройша–Пагана резко снижается до $LM \approx 45.1$ (хотя гетероскедастичность формально остаётся значимой: $p \approx 1.8 \cdot 10^{-11}$), что указывает на существенное улучшение (рис. 4).

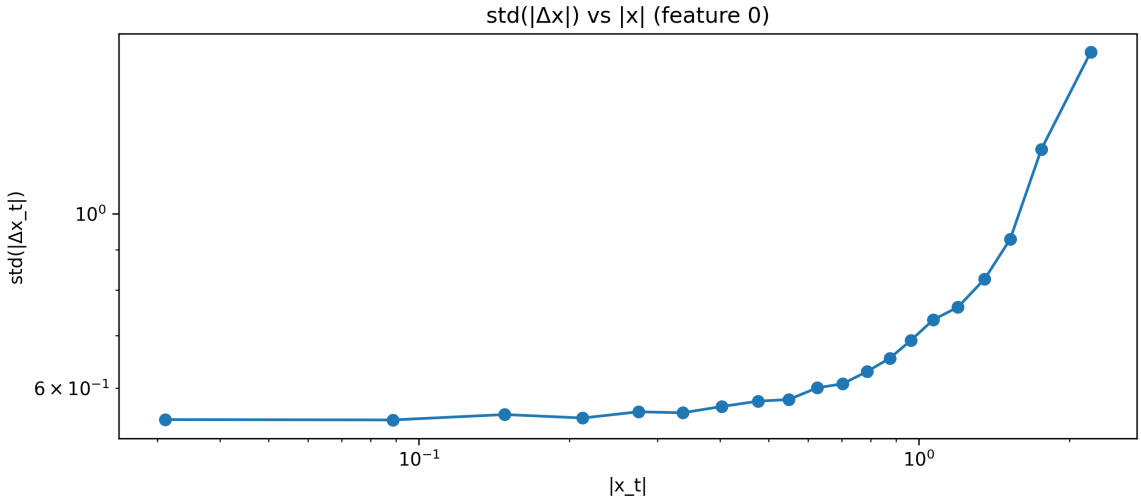

Рис. 3: Рост std($|\Delta x|$) при росте $|x|$.

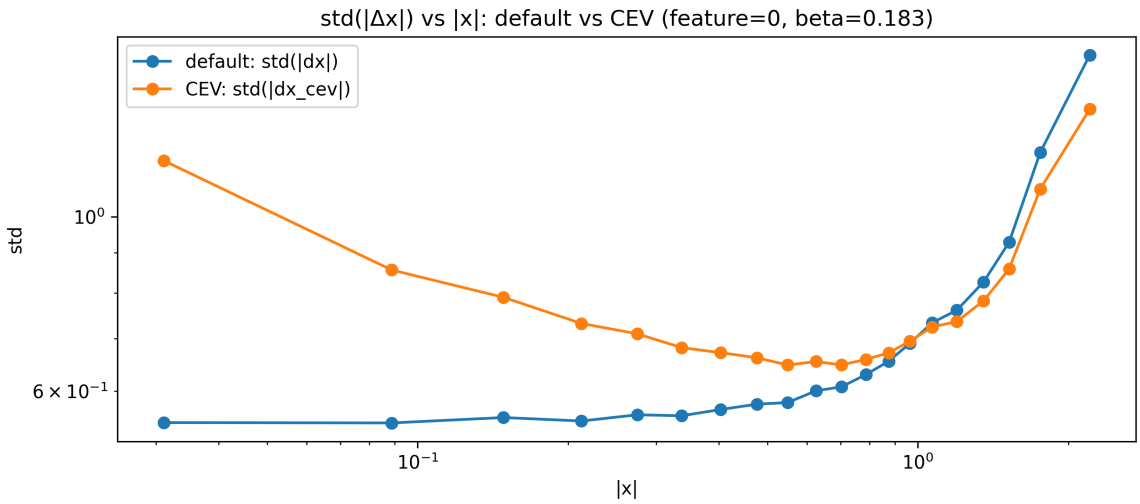

Рис. 4: Сравнение std($|\Delta x|$) до и после CEV-преобразования.

3.3 Волатильность по `step_in_seq`

Как и предыдущий блок цель этого тоже построить довольно сильную описательную модель ряда, которая в последствии будет использоваться в составлении ответа (см рис. 1). Для агрегирования масштаба по 32 координатам вводится показатель волатильности (просто (RMS) среднеквадратичная величина. Мы будем это называть волатильностью в дальнейшем, потому что данные отнормированы и выдвигается предположение соответствующее такой постановке $X \approx \sigma * \epsilon$, где $\mathbb{E}[\epsilon] = 0$, $Var[\epsilon] = 1$. Сигму можно по сути воспринимать как RMS (среднеквадратичное), потому что эта модель описывает логику, что на каждом шаге в ряду вектор по каждой координате изменяется (то есть масштабируется), т. е. получается что эта модель описывает ситуацию, где на каждом шаге просто с каким-то коэфициентом масштабируется (ϵ просто отнормирован).

Поэтому далее я буду называть волатильностью "масштабы"векторов

$$z_{\text{raw}}(t) = \sqrt{\frac{1}{32}\sum_{k=1}^{32} x_{t,k}^2}, \tag{6}$$

затем оценивается усреднённая по `step_in_seq` $= 21$ зависимость z_{raw} и её сглаживание скользящим окном (рис. 5). Нормированный остаток

$$z_{\text{resid}}(t) = \frac{z_{\text{raw}}(t)}{z_{\text{term}}(\texttt{step_in_seq}(t)) + \varepsilon} \tag{7}$$

имеет выраженную временную зависимость (средняя ACF на выборке последовательностей, рис. 7), что интерпретируется как кластеризация волатильности.

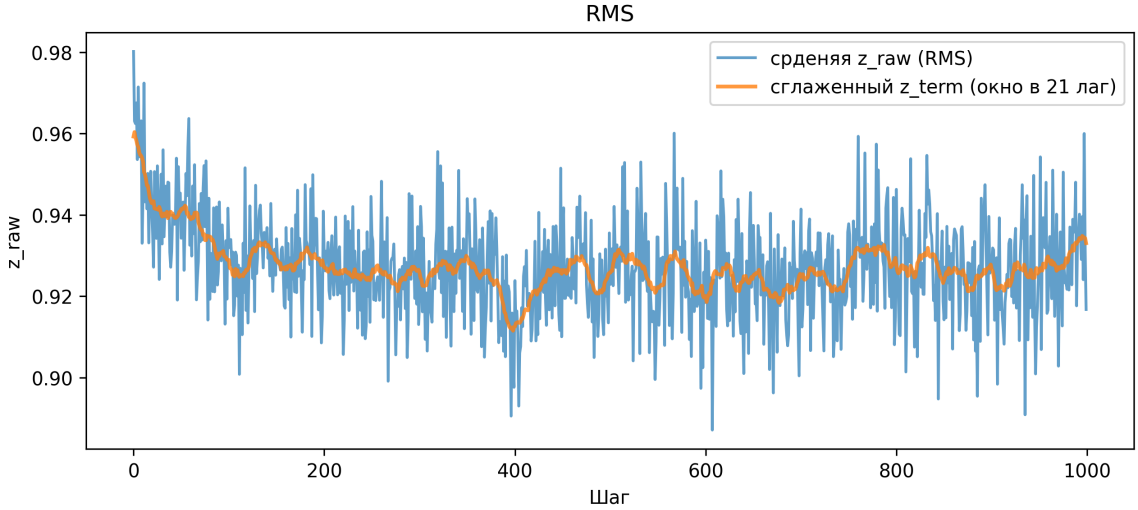

Рис. 5: z_{raw} и сглаженный z_{term} по `step_in_seq` $= 21$.

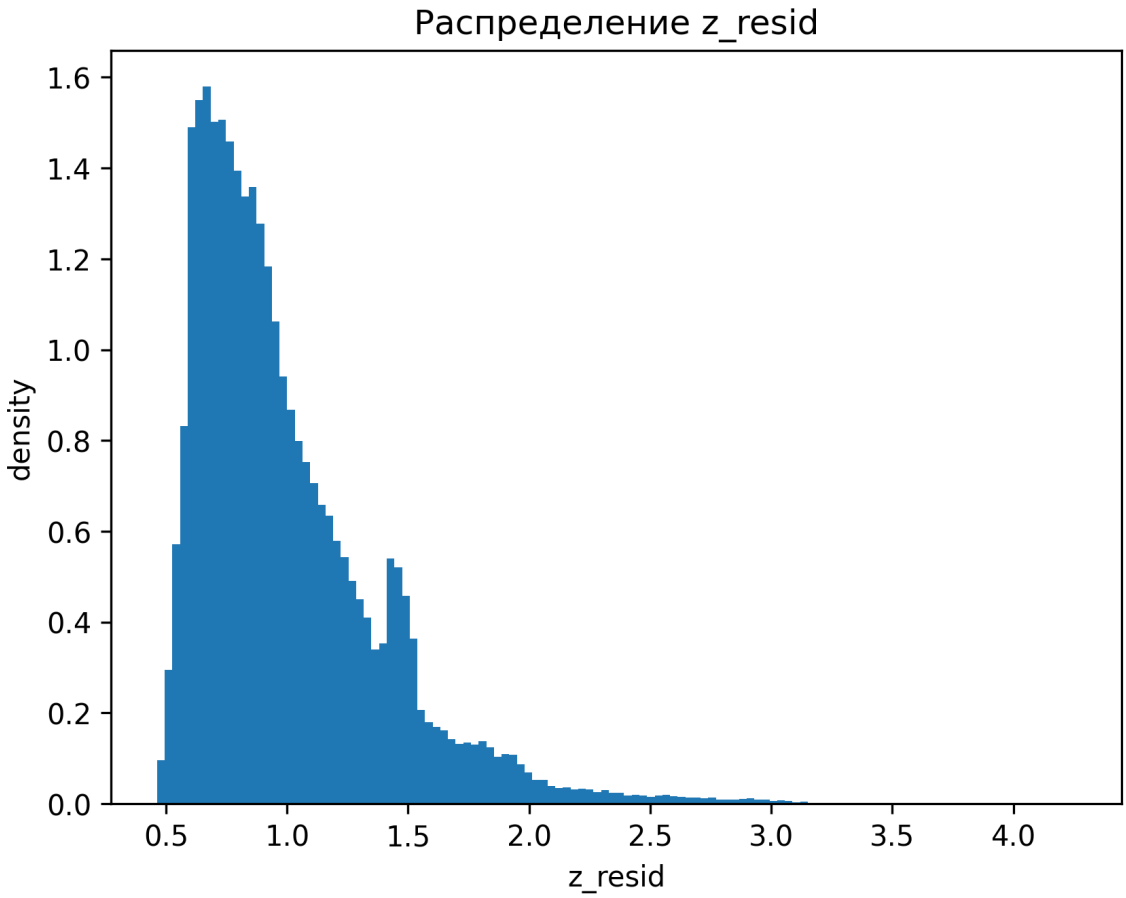

Рис. 6: Распределение z_{resid} .

В распределении z_{resid} видна асимметрия то есть правый хвост более тяжёлый, более того видна вторая мода даже, то есть скорее всего в нашем ряде может быть два режима. (в теории оценке активов, есть концепция, что у рынка есть конечное количество состояний и периодически рынок меняет эти состояния, тем самым активы переходят в

новые ценовые значения). Моя идея заключается в том чтобы развить ту концепцую и задать процесс случайного блуждания между этими состояниями.

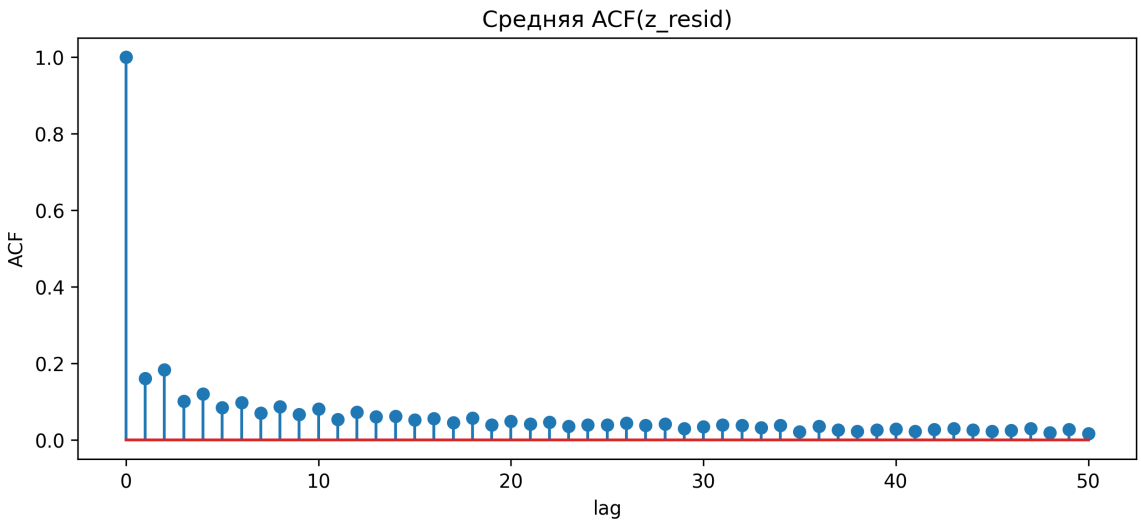

Рис. 7: ACF z_{resid} по семплам

3.4 HMM для z_{resid}: режимы волатильности и поправка на режимность для последующих моделей

$$z_{\text{resid}}(t) = \frac{z_{\text{raw}}(t)}{z_{\text{term}}(\texttt{step_in_seq}(t)) + \varepsilon}$$

Ранее при анализе распределения z_{resid} была выдвинута гипотеза о режимности, давайте её реализуем с помощью техники скрытых марковским моделей (hmm).

Теоретическая выкладка:

Постановка HMM. Пусть наблюдение y_t строится из $z_{\text{resid}}(t)$ (например, $y_t = \log(z_{\text{resid}}(t) + \epsilon)$ для стабилизации масштаба). Вводим скрытое состояние (режим) $s_t \in \{1, \ldots, K\}$, которое эволюционирует как марковская цепь первого порядка:

$$\mathbb{P}(s_t = j \mid s_{t-1} = i) = A_{ij}, \qquad \sum_{j=1}^{K} A_{ij} = 1, \tag{8}$$

с начальным распределением $\pi_j = \mathbb{P}(s_1 = j)$. Наблюдения условно независимы при фиксированных состояниях:

$$p(y_{1:T}, s_{1:T}) = \pi_{s_1}\, p(y_1 \mid s_1) \prod_{t=2}^{T} A_{s_{t-1}, s_t}\, p(y_t \mid s_t). \tag{9}$$

В качестве эмиссии (распределения наблюдений) удобно взять нормальную модель

$$p(y_t \mid s_t = k) = \mathcal{N}(y_t; \mu_k, \sigma_k^2), \tag{10}$$

что эквивалентно логнормальной модели для z_{resid} при выборе $y_t = \log(z_{\text{resid}} + \epsilon)$.

Оценивание параметров (EM). Параметры $\theta = \{\pi, A, (\mu_k, \sigma_k^2)_{k=1}^K\}$ оцениваются максимизацией правдоподобия $p(y_{1:T} \mid \theta)$. В EM-подходе на E-шаге вычисляются апостериорные вероятности состояний (forward–backward):

$$\alpha_t(k) = p(y_{1:t}, s_t = k \mid \theta), \tag{11}$$

$$\beta_t(k) = p(y_{t+1:T} \mid s_t = k, \theta), \tag{12}$$

$$\gamma_t(k) = p(s_t = k \mid y_{1:T}, \theta) = \frac{\alpha_t(k)\beta_t(k)}{\sum_{\ell=1}^K \alpha_t(\ell)\beta_t(\ell)}. \tag{13}$$

Также вводится вероятность переходов

$$\xi_t(i,j) = p(s_t = i, s_{t+1} = j \mid y_{1:T}, \theta), \tag{14}$$

которая нужна для обновления матрицы переходов. На M-шаге параметры обновляются по стандартным формулам:

$$\pi_k^{\text{new}} = \gamma_1(k), \tag{15}$$

$$A_{ij}^{\text{new}} = \frac{\sum_{t=1}^{T-1} \xi_t(i,j)}{\sum_{t=1}^{T-1} \gamma_t(i)}, \tag{16}$$

$$\mu_k^{\text{new}} = \frac{\sum_{t=1}^{T} \gamma_t(k)\, y_t}{\sum_{t=1}^{T} \gamma_t(k)}, \qquad (\sigma_k^2)^{\text{new}} = \frac{\sum_{t=1}^{T} \gamma_t(k)\,(y_t - \mu_k^{\text{new}})^2}{\sum_{t=1}^{T} \gamma_t(k)}. \tag{17}$$

На практике мы используем малое K (обычно $K = 2$), интерпретируя состояния как *low-vol* и *high-vol* режимы.

Релаксация весов с учётом режимности в следующих этапах модели Основная цель впоследствии разделять два состояния рынка и предсказывать любой шаг взвешенно по вероятностям состояний:

$$w_{\text{high}}(t) = \gamma_t(\text{high}), \qquad w_{\text{low}}(t) = 1 - w_{\text{high}}(t). \tag{18}$$

Эти веса далее используются на этапе построения модели факторов/признаков:

- **Режимная линейная динамика.** При оценивании VAR(p) (или другой линейной модели) мы можем обучить две модели (для low/high) и смешивать их прогнозы через $w_{\text{low}}(t), w_{\text{high}}(t)$.
- **Нелинейная поправка на остатках.** Веса режима можно использовать как фичу для GRU по остаткам.

4 Понижение размерности и стационарность факторов

Для уменьшения размерности и устранения мультиколлинеарности применяется PCA по ковариационной матрице 32×32. Выбираем $F = 8$ первых компонент. Полученные факторы ортогональны: максимальная по модулю внедиагональная корреляция $\max|\mathrm{corr}(f_i, f_j)| \approx 2.55 \cdot 10^{-14}$, см. рис. 9.

Для проверки стационарности факторов используется ADF-тест (по каждой последовательности; затем агрегирование). Для всех 8 факторов медианные p-значения чрезвычайно малы, доля отклонений нулевой гипотезы о единичном корне на уровне 5% превышает 0.98 (табл. 1), что позволяет использовать VAR на факторах без дополнительного дифференцирования.

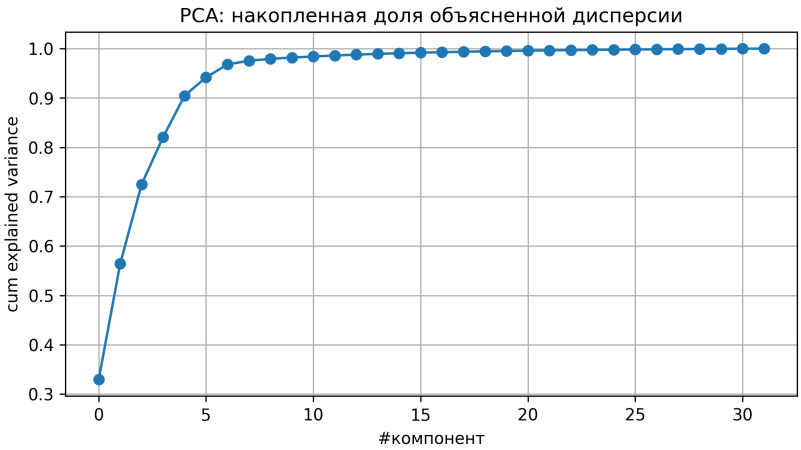

Рис. 8: Объясняемая дисперсия факторами.

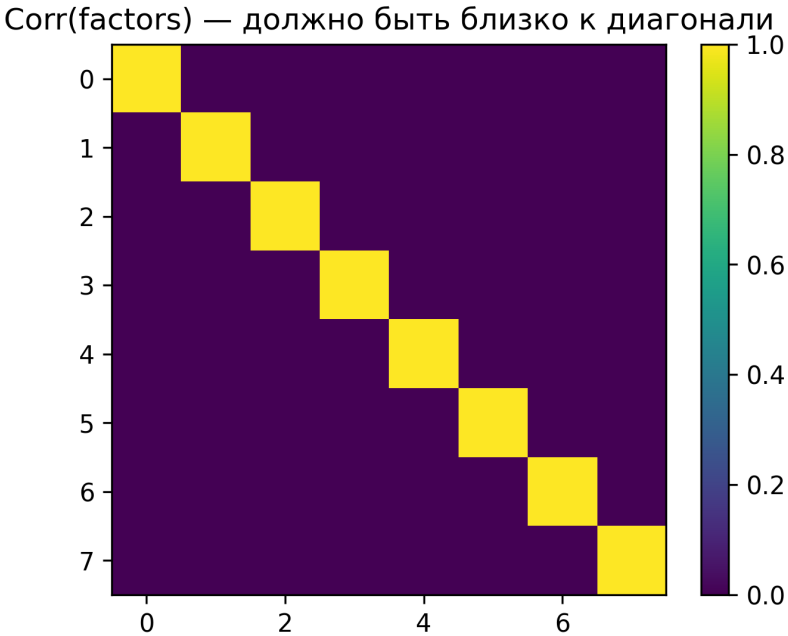

Рис. 9: матрица корреляции $\mathrm{corr}(f)$ для 8 PCA-факторов.

Таблица 1: ADF PCA-факторов.

Фактор	median p (ADF)	процент отвержений 5%
0	1.07e-14	0.990
1	1.65e-17	0.985
2	7.34e-26	0.990
3	2.38e-27	0.990
4	5.36e-28	0.988
5	1.10e-20	0.990
6	3.61e-23	0.986
7	9.81e-30	0.994

5 Модели

5.1 Разбиение train/validation

Сплит на трейн/валидацию 80% на 20%.

5.2 Модель A: режимная ridge-VAR(1) на факторах

На факторах $f_t \in \mathbb{R}^F$ рассматривается VAR(1):

$$f_{t+1} = Af_t + c + \varepsilon_{t+1}. \tag{19}$$

Параметры оцениваются раздельно для low/high режимов методом взвешенной ridge-регрессии:

$$\hat{B} = \arg\min_B \sum_t w(t)\|f_{t+1} - B^\top[f_t; 1]\|_2^2 + \lambda\|B\|_F^2, \tag{20}$$

где $\lambda = 10^{-3}$ (параметр для штрафа).

5.3 Модель B: режимная ridge-VAR(p) и выбор порядка

Обобщим до VAR(p) на факторах:

$$f_{t+1} = A_1 f_t + A_2 f_{t-1} + \cdots + A_p f_{t-p+1} + c + \varepsilon_{t+1}. \tag{21}$$

Для каждого p строится матрица из лагов внутри каждой последовательности, а оценка снова проводится взвешенной ridge-регрессией отдельно для low/high режимов. На валидации минимизируется MSE в пространстве факторов.

Результаты подбора p на валидации приведены в табл. 2: качество монотонно улучшается на сетке $p = 1, \ldots, 10$, лучшим оказался $p = 10$ (val MSE ≈ 2.955).

Таблица 2: Подбор порядка VAR(p) по MSE на валидации (в пространстве факторов).

p	val MSE (factors)
1	3.228321
2	3.078933
3	3.040981
4	3.009664
5	2.996109
6	2.980911
7	2.973454
8	2.964911
9	2.960862
10	2.954686

Итоговый прогноз факторов строится как смесь режимных прогнозов:

$$\hat{f}_{t+1} = w_{\text{low}}(t)\, \hat{f}_{t+1}^{(L)} + w_{\text{high}}(t)\, \hat{f}_{t+1}^{(H)}. \tag{22}$$

Переход обратно к 32 признакам выполняется через PCA-матрицу нагрузок $P \in \mathbb{R}^{32\times F}$:

$$\hat{x}_{t+1} = \hat{f}_{t+1} P^{\top}. \tag{23}$$

6 Диагностика предпосылок и качества

6.1 Гаусс–Марков и практические нарушения

Для временных рядов гаусс–марков часто нарушается, будем учитывать, что это лишь вспомогательная модель к основной GRU, которая добьёт остатки. В классической линейной регрессии условия Гаусса–Маркова требуют, в частности, гомоскедастичности и отсутствия автокорреляции ошибок. Для временных рядов эти условия часто нарушаются.

Гетероскедастичность. хотя CEV-преобразование снижает статистику (до $LM \approx 45.1$), полностью ряд не приводится к гомоскдастичности.

Автокорреляция остатков. Для режимной VAR(1) тест Льюнга–Бокса на лагах 20 отвергает отсутствие автокорреляции для всех компонент (доля $p < 0.05$ равна 1.0 как в low, так и в high режимах). Для лучшей модели VAR(10) ситуация сохраняется: доля $p < 0.05$ на лаге 20 равна 1.0.

ARCH-эффекты. ARCH-тест также отвергает отсутствие условной гетероскедастичности (доля отклонений 1.0, медианное $p = 0$), что согласуется с наблюдаемой кластеризацией волатильности.

Экзогенность ошибок. Получили оценку максимальной по модулю корреляции компонент ошибки с регрессорами f_t: для low режима ≈ 0.232, для high режима ≈ 0.053.

Это не доказывает строгое выполнение предпосылок, но показывает, что в high режиме ошибки ближе к "ортогональным"к регрессорам.

6.2 Вневыборочная оценка и сравнение с бейзлайном

Качество итоговой модели:

$$\overline{R^2} \approx 0.2728, \qquad \text{median}(R^2) \approx 0.2676.$$

Наиболее предсказуемые координаты (по R^2): `7, 14, 20, 6, 13` (до ≈ 0.43), наименее предсказуемые: `19, 21, 4, 1, 5` (около 0.16–0.18), см. табл. 3.

Для сравнения, наивный бейзлайн персистентности $x_{t+1} \approx x_t$ даёт среднее качество $R^2 \approx -0.400$, то есть хуже константного прогноза по среднему.

Таблица 3: Лучшие и худшие координаты по R^2 (валидация, `need_prediction=1`).

Worst dim	R^2	Best dim	R^2
19	0.156275	7	0.429436
21	0.158746	14	0.428968
4	0.163802	20	0.419322
1	0.169340	6	0.416848
5	0.175611	13	0.381086

7 GRU по остаткам

После построения линейного прогноза $\hat{x}^{\text{lin}}_{t+1}$ вычисляем остаток

$$r_{t+1} = x_{t+1} - \hat{x}^{\text{lin}}_{t+1}.$$

Далее обучаем GRU предсказывать $\hat{r}_{t+1}$ по окну прошлых остатков (и при необходимости по контексту режима):

$$\hat{r}_{t+1} = \text{GRU}\big(r_t, r_{t-1}, \ldots, r_{t-L+1};\ w_{\text{high}}(t)\big),$$

(на практике ещё также GRU получало на вход фурье признаки, волатильность, нормированные приращения) а итоговый прогноз задаём как сумму линейной части и нелинейной поправки:

$$\hat{x}_{t+1} = \hat{x}^{\text{lin}}_{t+1} + \hat{r}_{t+1}.$$

Такой подход набрал вместе с VAR(1) (по какой-то причине я к концу соревнования забыл обучить вес на VAR(p) p >= 10 тогда бы был бы результат даже лучше) набрал на приватном лидерборде $R^2 \approx 37.95$ (ivn1k).

8 Выводы

В работе построен пайплайн для прогноза многомерных последовательностей: PCA для снижения размерности и режимно-взвешенная ridge-VAR(p) регрессия. Были нормализованны данные и понижена сильная гетероскедастичность и неоднородность масштаба по `step_in_seq` = 21. Подбор порядка p на валидации показал оптимальное значение, а итоговая модель существенно превосходит наивные предсказанияR^2. Потенциальные улучшения: продолжать искать преобразования для понижения гетероскедастичности, а также тюнинг модели и более сложная архитектура МЛ части решения`seq_ix`.